



Faculté d'Économie - Campus Richter

PROJET TUTORÉ

**Présenté en vue de l'obtention du diplôme de
Data Analyst-Informatique et Statistique pour la
décision**

**Détection des fraudes dans les transactions
bancaires**

Présenté par :

Kobenan Gboko

Encadré par :

Thierry BLAYAC

**Année universitaire :
2025-2026**

Table des matières

1	Résumé exécutif	2
2	Contexte et question de recherche	3
2.1	Contexte.....	3
2.2	Objectifs.....	3
2.3	Question de recherche.....	3
3	Données utilisées	3
3.1	Source.....	3
3.2	Variables	4
3.3	Déséquilibre des classes.....	4
3.4	Distribution des montants	4
3.5	Limites des données	4
4	Méthodes et logiciels	5
4.1	Prétraitement des données	5
4.2	Modèles sous Python	5
4.3	Analyse SAS.....	8
5	Résultats obtenus.....	12
5.1	Résultats descriptifs	12
5.2	Résultats Python.....	12
5.3	Résultats SAS	13
5.4	Rôle des outils (Python, SAS)	13
6	Synthèse et perspectives	13

1 Résumé exécutif

Les fraudes par carte représentent des coûts considérables pour les banques et provoquent une perte de confiance chez les clients. Les détecter est difficile pour deux raisons structurelles : en ne représentant qu'environ 0,5 % des transactions, leur caractère rare fait que tout faux positif pénalise un client innocent.

Ce travail vise à analyser des données transactionnelles anonymisées pour dégager les particularités des fraudes et comparer l'aptitude de différentes méthodes à les identifier. Nous avons utilisé python pour une analyse exploratoire et une modélisation prédictive, tandis que SAS est mobilisé pour l'analyse statistique, la régression logistique interprétable dans cette approche.

L'étude révèle que, malgré le déséquilibre des classes, une détection satisfaisante est possible si la performance est mesurée avec des indicateurs appropriés (rappel, précision, aire sous la courbe ROC) et non avec l'accuracy. En matière de détection, le Random Forest est plus performant que la régression logistique. En matière d'explicabilité, la régression logistique SAS est la meilleure. Nous pouvons conclure que les deux approches sont complémentaires et non substituables.

2 Contexte et question de recherche

2.1 Contexte

L'essor des paiements électroniques a, parallèlement à sa simplification pour les consommateurs, accru les opportunités pour les fraudeurs. Face à l'augmentation des volumes de transactions, les acteurs financiers font face à des fraudes peu fréquentes, mais aux conséquences économiques et réputationnelles désastreuses.

Deux contraintes structurelles compliquent la détection. D'abord, le déséquilibre extrême entre classes rend les métriques classiques trompeuses. Ensuite, les systèmes doivent limiter les faux positifs : bloquer un paiement légitime nuit directement à l'expérience client. Les méthodes statistiques, de data science et machine learning sont aujourd'hui indispensables pour naviguer entre ces deux impératifs.

2.2 Objectifs

Le projet vise à :

- caractériser les transactions frauduleuses et les distinguer des transactions légitimes ;
- comparer les approches statistiques classiques et les méthodes de machine learning ;
- identifier les variables les plus discriminantes.
- montrer la complémentarité entre performance prédictive et interprétabilité.

2.3 Question de recherche

Dans quelle mesure les données transactionnelles permettent-elles de détecter les fraudes, et quels facteurs y sont le plus fortement associés ?

3 Données utilisées

3.1 Source

Le jeu de données utilisé pour ce projet est en réalité le dataset public Kaggle "Credit Card Fraud Detection", publié par des chercheurs de l'ULB (Université Libre de Bruxelles) en collaboration avec Worldline. Ils ont appliqué l'ACP précisément pour pouvoir partager les données sans exposer les clients ni les systèmes de détection internes de la banque. Elle contient des transactions bancaires authentiques, rendues anonymes et classifiées comme frauduleuses ou légitimes. Certaines informations ont été anonymisées parce qu'elles étaient probablement

sensibles : localisation, heure précise de la transaction, historique du client, etc. Publier directement toutes ces données aurait violé la vie privée des propriétaires de carte.

3.2 Variables

Description des variables

Time : Temps écoulé depuis la première transaction du jeu de données

Amount : Montant de la transaction

V1 à V28 : Composantes issues d'une analyse en composante principale (ACP) anonymisées

Class Variable cible : 1 = Fraude , 0 = Transaction normale

3.3 Déséquilibre des classes

Nous sommes face à des données déséquilibrés parce qu'une classe domine largement sur l'autre. 99,56 % des transactions sont normale et 0.44 % sont frauduleuse. Comme les transactions normales dominent, le modèle peut finir par ignorer les transactions frauduleuses. Pour résoudre ce problème il existe deux grandes approche. la première approche consiste à rééquilibrer les données en supprimant des transactions normales ou en dupliquant les transactions frauduleuses. On pourrait également créer de nouvelles transaction frauduleuses synthétiques ou créer des nouvelles transactions à la frontière entre les deux classes. La seconde approche consiste à pondérer les classes et à ne pas toucher les données d'entraînement.

Pour ce projet, nous nous basons sur le rappel (taux de fraudes détectées), la précision et l'aire sous la courbe ROC.

3.4 Distribution des montants

Les transactions frauduleuses affichent une dispersion plus large et des valeurs extrêmes plus fréquentes que les transactions légitimes. La variable Amount nous donne des information, mais elle doit être standardisée avant modélisation.

3.5 Limites des données

L'anonymisation des variables V1 à V28 est un obstacle à toute interprétation métier directe.

La disponibilité d'informations contextuelles telles que la localisation, type de personne, historique client etc, permettrait de réduire davantage le taux de faux positifs.

4 Méthodes et logiciels

4.1 Prétraitement des données


Sous Python : les observations incomplètes sont supprimées dans l'analyse. Ce choix s'explique par la minceur des données manquantes et par la nature déjà transformée des variables, rendant l'imputation inutile d'un point de vue interprétatif.

Sous SAS : Nous avons suivi la même procédure via PROC MEANS, par cohérence méthodologique. Seules les observations complètes ont été utilisées dans les analyses.

4.2 Modèles sous Python

Répartition des classes


En observant le graphique ci-dessous une chose saute immédiatement aux yeux : les données sont très déséquilibrées. Les fraudes sont tellement quasi inexistantes qu'elles ne sont pas visibles sur le graphique.



Montants des transactions

Les transactions normales présentent une grande dispersion : Une tendance centrale autour de 15 €, encadrée par un écart interquartile de 7 € à 50 €, et une extension de valeurs rares pouvant atteindre plus de 5 000 €.

Les transactions frauduleuses sont complètement à l'opposé : La majeure partie se situe à environ 1€, la médiane étant au plus bas et la dispersion très faible. Les valeurs excédant 100 à 1000€ constituent des cas exceptionnels et peu fréquents.



Régression logistique

Pour pallier le déséquilibre, le modèle prend en compte une pondération des classes. Le système identifie un nombre important de fraudes au détriment de faux positifs, ce qui est un échange acceptable dans le but de maximiser le rappel.

```

Régression logistique - Rapport de classification
              precision    recall  f1-score   support

    0.0         1.00        0.99        1.00       3821
    1.0         0.29        0.82        0.43         17

 accuracy         0.99         3838
 macro avg        0.65        0.91        0.71         3838
 weighted avg     1.00        0.99        0.99         3838
ROC AUC: 0.9456101728835998

```

Le modèle obtient globalement d'excellents résultats, comme en témoignent l'air sous la courbe ROC (0.94 %) et une bonne classification des transactions normales. Il parvient à détecter une grande partie des fraudes (recall de 82 %). Cependant, la faible précision pour la classe frauduleuse révèle un taux élevé de faux positifs. En agissant ainsi, on peut comprendre que le modèle privilégie la détection des fraudes au détriment de la fiabilité des alertes, ce qui peut entraîner des complications opérationnelles.

Random Forest

À la différence de la régression logistique, le Random Forest est capable de saisir les relations complexes et non-linéaires entre les variables. Il gagne en performance (rappel, AUC-ROC), mais devient moins interprétable.

```
Random Forest - Rapport de classification
              precision    recall  f1-score   support

         0.0         1.00        1.00        1.00        3821
         1.0         1.00        0.76        0.87         17


 accuracy         1.00        0.88        0.93        3838
 macro avg         1.00        0.88        0.93        3838
weighted avg         1.00        1.00        1.00        3838

ROC AUC: 0.9994919716119894
```

Avec une bonne précision et une aire sous la courbe ROC très proche de 1, le modèle offre des résultats qui sont globalement bons. Il identifie parfaitement les transactions normales et ne génère quasiment aucun faux positif. Seuls 76 % des montants provenant de transactions frauduleuses sont récupérés, ce qui indique que certaines fraudes échappent à la détection. Ce résultat s'explique notamment par le déséquilibre important des classes, et montre la nécessité d'améliorer la sensibilité du modèle dans un contexte où la détection des fraudes reste la priorité.

Comparaison des courbes ROC


La supériorité du Random Forest sur la régression logistique est manifeste sur l'ensemble des seuils de décision, son AUC plus élevée attestant d'une meilleure différence entre les deux classes.



Les courbes montrent que les deux modèles présentent de bonnes performances de classification. Les courbes sont nettement au-dessus de la diagonale. Le modèle Random Forest est plus performant que la régression logistique car sa courbe est plus proche du coin supérieur gauche. Cela traduit une meilleure capacité à faire la différence entre transactions frauduleuses et transactions normales. Notons qu'il est plus efficace dans la modélisation des relations complexes.

Importance des variables

L'analyse d'importance identifie les composantes qui contribuent le plus à la prédiction. Ces résultats nous permettent d'avoir des orientations sur les analyses futures.



Les variables V14, V12, V3 et V4 sont les plus discriminantes. Les autres variables contribuent de manière plus modérée. Cette configuration renforce l'idée que la fraude découle d'une interaction de causes et atteste de la performance du modèle pour identifier des liens subtils entre les variables. Il faut noter qu'il est difficile de faire une interprétation métier de ce résultat parce que les variables restent inconnus.

4.3 Analyse SAS

Ici nous avons utilisé l'environnement SAS pour faire une analyse statistique approfondie, permettant d'interpréter les facteurs associés à la fraude dans le secteur bancaire.

Analyse descriptive

PROC FREQ confirme le déséquilibre des classes. PROC MEANS confirme la variabilité accrue des montants pour les fraudes.

Class	Fréquence	Pourcentage
0	12736	99.56
1	56	0.44

Statistiques descriptives du montant selon la classe

La procédure MEANS

Variable d'analyse : Amount						
Class	N obs	Moyenne	Médiane	Ec-type	Minimum	Maximum
0	12736	62.0472566	15.6200000	175.0531244	0	7712.43
1	56	90.8158929	1.0000000	310.3084501	0	1809.68

Test de comparaison des moyennes

La différence de montants entre fraudes et transactions légitimes est statistiquement significative. Cette relation est réelle mais doit être interprétée avec prudence : la taille de l'échantillon amplifie mécaniquement la significativité.

La procédure TTEST

Variable : Amount

Class	Méthode	N	Moyenne	Ec-type	Err. type	Minimum	Maximum
0		12736	62.0473	175.1	1.5511	0	7712.4
1		56	90.8159	310.3	41.4667	0	1809.7
Diff (1-2)	Pooled		-28.7686	175.9	23.5516		
Diff (1-2)	Satterthwaite		-28.7686		41.4957		

Class	Méthode	Moyenne	IC à95% - Moyenne	Ec-type	Ec.-type de l'IC à95%
0		62.0473	59.0068	65.0877	175.1
1		90.8159	7.7147	173.9	310.3
Diff (1-2)	Pooled	-28.7686	-74.9332	17.3960	175.9
Diff (1-2)	Satterthwaite	-28.7686	-111.9	54.3854	


Méthode	Variances	DDL	Valeur du test t	Pr > t
Pooled	Egal	12790	-1.22	0.2219
Satterthwaite	Non égal	55.154	-0.69	0.4910

Egalité des variances

Méthode	DDL num.	DDL den.	Valeur F	Pr > F
Folded F	55	12735	3.14	<.0001

Le test d'égalité des variances indique que les variances des deux groupes sont significativement différentes ($p < 0,0001$). Par conséquent, l'interprétation doit se baser sur la méthode de Satterthwaite. Le test de Student ne met pas en évidence de différence significative entre les montants moyens des transactions frauduleuses et non frauduleuses ($p = 0,4910$). L'hypothèse nulle d'égalité des moyennes ne peut donc pas être rejetée.

Le graphique ci-dessous met en évidence une différence de montant moyen entre les transactions frauduleuses et non frauduleuses, les fraudes présentant des montants moyens plus élevés. L'intervalle de confiance est beaucoup plus large pour les transactions frauduleuses, on a une forte variabilité et une présence de valeurs extrêmes. Cette dispersion montre que la moyenne est fortement influencée par certains montants atypiques. Il faut donc faire une interprétation des résultats avec prudence. Cette observation explique pourquoi la médiane peut être plus pertinente que la moyenne pour décrire ce type de distribution.



Régression logistique explicative

Le modèle SAS identifie les variables significativement associées à la probabilité de fraude. Les odds ratios quantifient les effets : certaines variables augmentent le risque, d'autres le


réduisent. Contrairement au Random Forest, cette approche produit une lecture directe et mobilisable pour la décision.

Table de Class par pred_class			
Class	pred_class		
	0	1	Total
0	12733	3	12736
1	9	47	56
Total	12742	50	12792

Matrice de confusion

Nous avons un très faible nombre de faux positifs (3 seulement), une bonne précision ($47/50 = 94\%$) et un bon rappel ($47/56 = 84\%$). Aussi, nous avons un faible taux d'erreur $(3+9)/12792=0.09\%$.

La matrice de confusion montre que le modèle offre de très bonnes performances globales, avec une précision élevée et un nombre très limité de faux positifs. Il parvient à détecter environ 84 % des fraudes, ce qui constitue un bon niveau de performance. Toutefois, certaines transactions frauduleuses ne sont pas identifiées, ce qui souligne la nécessité d'améliorer encore la sensibilité du modèle dans un contexte où le coût des fraudes non détectées est élevé.



Le graphique met en évidence plusieurs variables fortement associées au risque de fraude, notamment V4 et V9, qui présentent un effet significativement positif. D'autres variables, comme V6, V8 et V10, jouent un rôle protecteur. Toutefois, la largeur des intervalles de confiance pour certaines variables révèle une incertitude dans les estimations, ce qui invite à interpréter les résultats avec prudence. Enfin, le montant des transactions ne semble pas constituer un facteur déterminant dans ce modèle.

5 Résultats obtenus

5.1 Résultats descriptifs

Le jeu de données présente trois caractéristiques structurelles clés :

Déséquilibre sévère. Les fraudes représentent moins de 0,5 % des transactions. Cette faible taux de fraude rend la détection un peu plus difficile et impose des métriques d'évaluation adaptées.

Montants atypiques. Les fraudes au niveau des transactions présentent une disparité plus marquée et de nombreux cas extrêmes. Amount est une variable importante, mais pas suffisante.

Différences dans les composantes ACP. Plusieurs variables V1 à V28 présentent des distributions distinctes selon la classe, ce qui justifie leur intégration dans des modèles de classification.

5.2 Résultats Python

Un volume important de fraudes est mis en évidence par la régression logistique pondérée. Elle produit des faux positifs, un effet inévitable lors de la maximisation du rappel, tout en demeurant un modèle compréhensible et facile à auditer d'audit.

Le Random Forest a permis une amélioration des deux métriques clés utilisées : rappel et AUC-ROC. Il détecte des corrélations que la régression linéaire n'arrive pas à détecter. Sa limite principale est l'interprétabilité : comprendre pourquoi il signale une transaction comme frauduleuse est difficile, ce qui pose un problème dans les contextes réglementaires ou de contestation client.

La comparaison des courbes ROC montre clairement que le Random Forest est plus efficace. Son pouvoir discriminant est supérieur sur l'ensemble des seuils.

L'analyse d'importance des variables montre que certaines composantes ont une plus grande importance dans la prédiction. On peut utiliser ces résultats pour hiérarchiser les contrôles, sans même avoir besoin d'une interprétation métier directe.

5.3 Résultats SAS

Les analyses descriptives confirment ce qu'on avait pu observer avec Python : un déséquilibre des classes, une variabilité des montants.

Le test de comparaison des moyennes sur l'Amount établit un lien statistiquement significatif avec la classe fraude.

Bien que le graphique des moyennes montre un écart entre les transactions frauduleuses et non frauduleuses, le test de Student montre que cet écart n'est pas statistiquement significatif. Ce résultat s'explique par la forte variabilité des montants et la présence de valeurs extrêmes, qui affectent la stabilité de la moyenne.

Les résultats de la régression logistique sont les plus immédiatement utilisables dans un contexte opérationnel : plusieurs variables sont significativement associées au risque de fraude, avec des odds ratios que l'on peut interpréter. Certaines augmentent la probabilité de fraude, d'autres la réduisent. Ce modèle peut directement être utilisé pour justifier une décision de blocage ou d'alerte afin de protéger les utilisateurs.

5.4 Rôle des outils (Python, SAS)

L'objectif est de maximiser la détection de fraude avec Python (random Forest), expliquer et justifier la fraude avec SAS (régression logistique). Ces deux approches sont complémentaires, alors pour avoir un dispositif plus efficace, nous aurons besoin des deux.

6 Synthèse et perspectives

Sous réserve de l'utilisation de métriques adaptées et de modèles capables de traiter le déséquilibre des classes, les informations contenues dans les données transactionnelles anonymisées sont suffisantes pour une détection de fraude satisfaisante. Le Random Forest surpasse la régression logistique en matière de performance brute. Les résultats de la régression logistique sous SAS sont immédiatement utilisables pour une prise de décision.

Le caractère anonymisé des variables V1 à V28 rend l'analyse difficile à relier à des situations concrètes. À cela s'ajoute le manque d'informations contextuelles comme la localisation, le

type, ou le profil client. Le modèle voit ses performances diminuer, ce qui laisse place à un nombre important de faux positifs.

Il serait plus pertinent d'ajouter des données contextuelles non anonymisées, ce qui nous permettra d'enrichir les modèles et aussi d'améliorer leur capacité de discrimination. De même, tester des méthodes plus avancées comme le gradient boosting ou les réseaux de neurones permettrait d'évaluer d'éventuels gains en performance sur les mêmes données. Enfin, Pour une meilleure réactivité face aux comportements frauduleux, il est essentiel de déployer des modèles en temps réel et d'assurer un suivi régulier de la dérive des prédictions.

Le déséquilibre des classes est le principal obstacle à la détection de fraude. Les modèles ont tendance à ignorer les classes minoritaires s'il n'y a pas de réelle rééquilibrage.